

Унификация посредством поиска путей с контекстно-свободными ограничениями в графе Source-tracking unification

Екатерина Вербицкая

Лаборатория языковых инструментов JetBrains

6 ноября 2020

Задачу унификации можно свести к
поиску путей с КС ограничениями в графе¹

¹Choppella, V., and Haynes, C. T. (2005). Source-tracking unification.

- Что такое унификация
- Как задача унификации представима в виде графа
- Какой язык будем использовать в качестве ограничений
- Почему это работает
- Какую дополнительную информацию можно получить из пути

Даны два терма t, s

Задача: найти подстановку на свободных переменных термов
(унификатор) θ , такую что

$$t\theta = s\theta$$

Терм: $\mathcal{T} :: \mathcal{V} \mid \mathcal{F}^n \mathcal{T}_1 \dots \mathcal{T}_n$

Подстановка: $\theta :: \mathcal{V} \rightarrow \mathcal{T}$

Применение подстановки $t\{x_1 \mapsto t_1, \dots, x_k \mapsto t_k\}$:
одновременно заменить свободные переменные x_i терма t на t_i

$$(f \ x \ a \ (g \ z) \ y)\{x \mapsto h \ a \ y, z \mapsto y\} = f \ (h \ a \ y) \ a \ (g \ y) \ y$$

Применение унификации

```
apply :: (a -> b) -> a -> b
```

```
apply f x = f x
```

```
f :: Int -> Int
```

```
f x = x + 1
```

```
apply_f :: ?
```

```
apply_f = apply f
```

Унифицируем $a \rightarrow b$ и $\text{Int} \rightarrow \text{Int}$, получаем $a == \text{Int}$, $b == \text{Int}$

```
apply_f :: Int -> Int
```

Простой алгоритм унификации

Будем искать подстановку как множество уравнений $\mathcal{E} = \{t_i = s_i\}$

- Упрощение термов: $(f\ t_1 \dots t_n = g\ s_1 \dots s_m) \in \mathcal{E}$
 - ▶ Если f, g — различные константы, то $\mathcal{E} = \perp$
 - ▶ Иначе заменяем уравнение в \mathcal{E} на множество $t_1 = s_1, \dots, t_n = s_n$
- Переориентация: $(t = x) \in \mathcal{E}$
 - ▶ Если t — терм, x — переменная, заменяем в \mathcal{E} уравнение на $x = t$
- Элиминация переменных: $(x = t) \in \mathcal{E}$, x входит в какое-то уравнение
 - ▶ Если x входит в t , $t \equiv x$, то удаляем уравнение из \mathcal{E}
 - ▶ Иначе, если x входит в t , то $\mathcal{E} = \perp$
 - ▶ Иначе, подставляем t вместо x во всех уравнениях в \mathcal{E}

Унификация: пример

$$\{node\ El\ T\ T = node\ 1\ (node\ 2\ emp\ emp)\ (node\ 2\ emp\ emp)\}$$
$$\{El = 1, T = node\ 2\ emp\ emp, T = node\ 2\ emp\ emp\}$$
$$\{El = 1, T = node\ 2\ emp\ emp, node\ 2\ emp\ emp = node\ 2\ emp\ emp\}$$
$$\{El = 1, T = node\ 2\ emp\ emp, 2 = 2, emp = emp, emp = emp\}$$
$$\{El = 1, T = node\ 2\ emp\ emp\}$$

Унификация: пример

$$\{node\ El\ T\ T = node\ 1\ (node\ 2\ emp\ emp)\ (node\ 3\ emp\ emp)\}$$

$$\{El = 1, T = node\ 2\ emp\ emp, T = node\ 3\ emp\ emp\}$$

$$\{El = 1, T = node\ 2\ emp\ emp, node\ 2\ emp\ emp = node\ 3\ emp\ emp\}$$

$$\{El = 1, T = node\ 2\ emp\ emp, 2 = 3, emp = emp, emp = emp\}$$


⊥

Чем плох простой алгоритм

- Не очень эффективный
- Не говорит, почему унификация не завершилась успехом


Граф унификации

$$a \rightarrow b \stackrel{?}{=} \text{Int} \rightarrow \text{Int}$$




Граф унификации

$$a \rightarrow b \stackrel{?}{=} \text{Int} \rightarrow \text{Int}$$



Отношение эквивалентности на вершинах


Отношение на вершинах R замкнуто вниз, если для любой метки на ребре δ и двух вершин в отношении uRu' с ребрами $u \xrightarrow{\delta} v$ и $u' \xrightarrow{\delta} v'$ верно vRv'



Замыкание унификации отношения R это наименьшее замкнутое вниз отношение на вершинах, содержащее R

Отношение эквивалентности на вершинах

Отношение на вершинах R замкнуто вниз, если для любой метки на ребре δ и двух вершин в отношении uRu' с ребрами $u \xrightarrow{\delta} v$ и $u' \xrightarrow{\delta} v'$ верно vRv'



Замыкание унификации отношения R это наименьшее замкнутое вниз отношение на вершинах, содержащее R

Факторграф унификации


Вершины *равны*, если связаны ε -ребром

Факторизуем граф унификации по отношению эквивалентности на вершинах, которое построено как замыкание унификации отношения равенства вершин

Факторграф унификации

Вершины *равны*, если связаны ε -ребром

Факторизуем граф унификации по отношению эквивалентности на вершинах, которое построено как замыкание унификации отношения равенства вершин



Унификация невозможна, если в факторграфе есть вершина с разными функциональными символами

Большой пример

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \textit{bool}$$

$$t_4 \stackrel{?}{=} t_5$$

$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \textit{int} \rightarrow \textit{int}$$

$$t_7 \stackrel{?}{=} t_1$$

Большой пример

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$


$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$


$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$


$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$

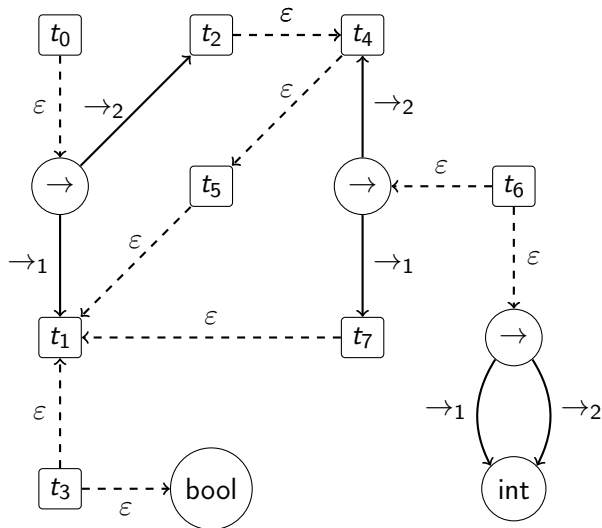
$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример: $t_7 = int$

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} bool$$

$$t_4 \stackrel{?}{=} t_5$$

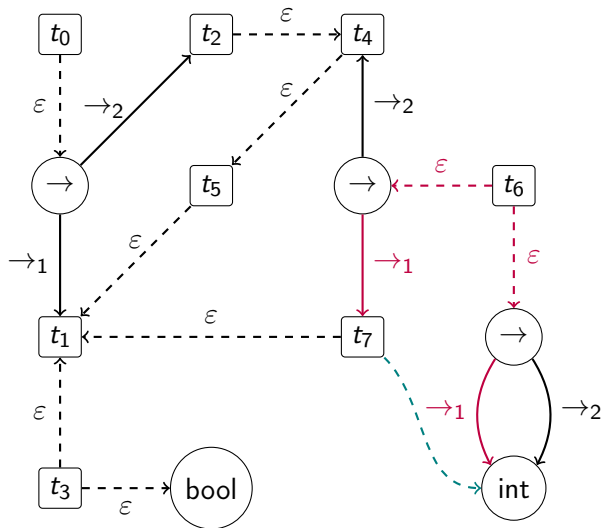
$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} int \rightarrow int$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример: $t_4 = int$

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} bool$$

$$t_4 \stackrel{?}{=} t_5$$


$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} int \rightarrow int$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример: $t_7 = \text{bool}$

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$

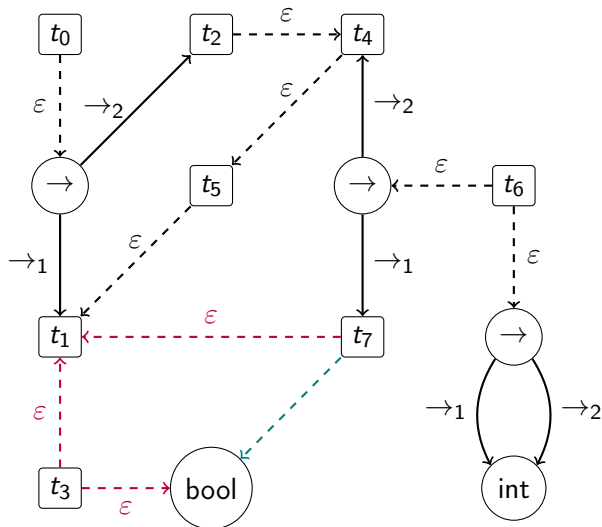
$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Большой пример: $t_4 = \text{bool}$

$$t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$t_2 \stackrel{?}{=} t_4$$

$$t_3 \stackrel{?}{=} \text{bool}$$

$$t_4 \stackrel{?}{=} t_5$$

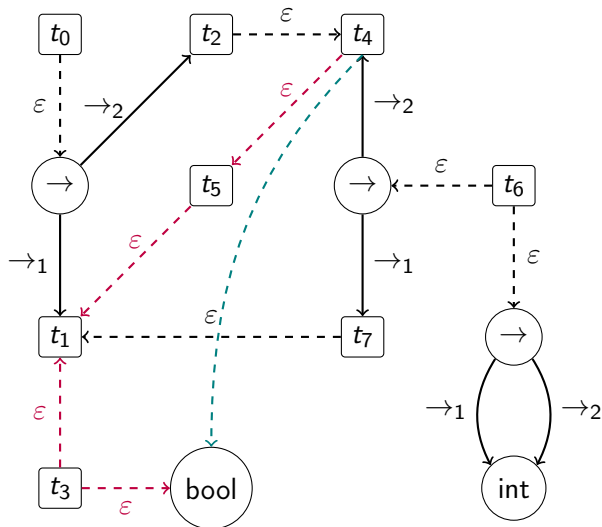
$$t_3 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

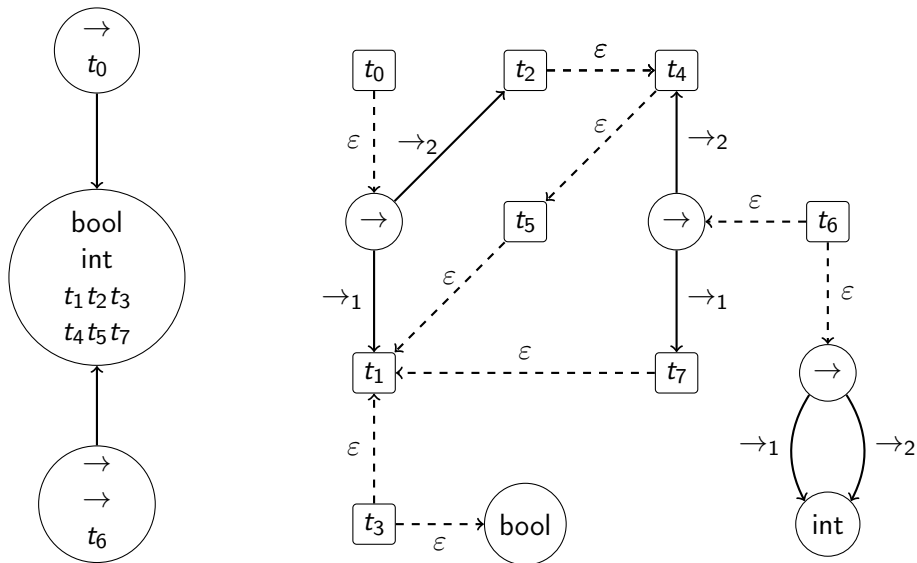
$$t_5 \stackrel{?}{=} t_1$$

$$t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$t_7 \stackrel{?}{=} t_1$$



Факторграф для примера: унификация невозможна



Полудиков язык: соотношения отмены

$$\Sigma = \{\delta_1, \dots, \delta_n\}$$

$$\Sigma^{-1} = \{\delta_1^{-1}, \dots, \delta_n^{-1}\}$$

$$\Sigma \cap \Sigma^{-1} = \emptyset$$

$$\mathbf{S}(\Sigma) = \{\delta^{-1}\delta \approx \varepsilon \mid \delta \in \Sigma\}$$

$$\mathbf{S}_2(\Sigma) = \{\delta^{-1}\delta \approx \varepsilon, \delta\delta^{-1} \approx \varepsilon \mid \delta \in \Sigma\}$$

$u \stackrel{\mathbf{S}(\Sigma)}{\approx} v$, если u можно получить из v применением равенств из $\mathbf{S}(\Sigma)$

(или наоборот, v из u ; аналогично для $u \stackrel{\mathbf{S}_2(\Sigma)}{\approx} v$)

$\mu_{\mathbf{S}(\Sigma)}(l)$ — нормальная форма l относительно равенств из $\mathbf{S}(\Sigma)$

$\mu_{\mathbf{S}_2(\Sigma)}(l)$ — нормальная форма l относительно равенств из $\mathbf{S}_2(\Sigma)$

$$S(\Sigma, L) \stackrel{\text{def}}{=} \{l \in (\Sigma \cup \Sigma^{-1})^* \mid \mu_{\mathbf{S}(\Sigma)}(l) \in L\}$$

$$S_2(\Sigma, L) \stackrel{\text{def}}{=} \{l \in (\Sigma \cup \Sigma^{-1})^* \mid \mu_{\mathbf{S}_2(\Sigma)}(l) \in L\}$$

$$S^0(\Sigma) = S(\Sigma, \varepsilon)$$

$$S_2^0(\Sigma) = S(\Sigma, \varepsilon)$$

$$S^+(\Sigma) = S(\Sigma, \Sigma^+)$$

$$S_2^+(\Sigma) = S(\Sigma, \Sigma^+)$$


$$S^*(\Sigma) = S(\Sigma, \Sigma^*)$$

$$S_2^*(\Sigma) = S(\Sigma, \Sigma^*)$$


$S^0(\Sigma)$ — полудиков язык (semi-Dyck set)

²Определение полудикова языка может показаться неожиданным


Пути унификации: обращение ребер



Пути унификации: обращение ребер



$$\varepsilon^{-1} = \varepsilon$$



Путь унификации — такой путь p в графе $G \cup G^{-1}$, что нормальная форма его метки $\mu_{S(\Sigma)}(I(p)) \in \Sigma^*$

G — граф унификации, G^{-1} — граф с обращенными ребрами

Путь унификации: пример

$$\mu_{\mathcal{S}(\Sigma)}(l(p^{-1}f^{-1}hr)) = \mu_{\mathcal{S}(\Sigma)}((\rightarrow_1)^{-1} \rightarrow_1) = \varepsilon \in \Sigma^*$$

$$a : t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$b : t_2 \stackrel{?}{=} t_4$$

$$c : t_3 \stackrel{?}{=} \text{bool}$$

$$d : t_4 \stackrel{?}{=} t_5$$

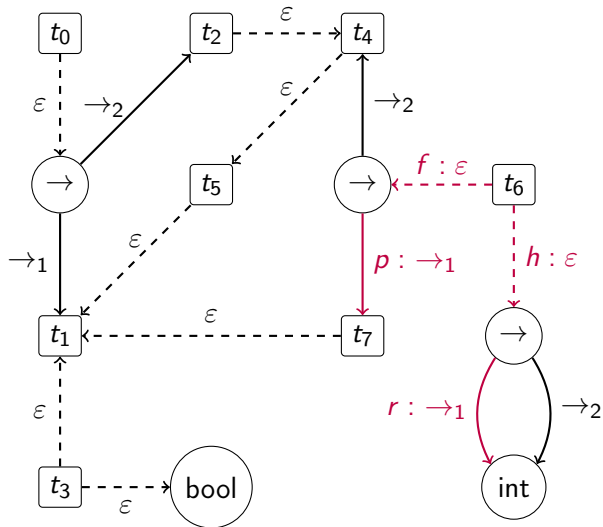
$$e : t_3 \stackrel{?}{=} t_1$$

$$f : t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$g : t_5 \stackrel{?}{=} t_1$$

$$h : t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$i : t_7 \stackrel{?}{=} t_1$$



Путь унификации: пример

$$\mu_{\mathcal{S}(\Sigma)}(l(s^{-1}f^{-1}hq)) = \mu_{\mathcal{S}(\Sigma)}((\rightarrow_2)^{-1} \rightarrow_2) = \varepsilon \in \Sigma^*$$

$$a : t_0 \stackrel{?}{=} t_1 \rightarrow t_2$$

$$b : t_2 \stackrel{?}{=} t_4$$

$$c : t_3 \stackrel{?}{=} \text{bool}$$

$$d : t_4 \stackrel{?}{=} t_5$$

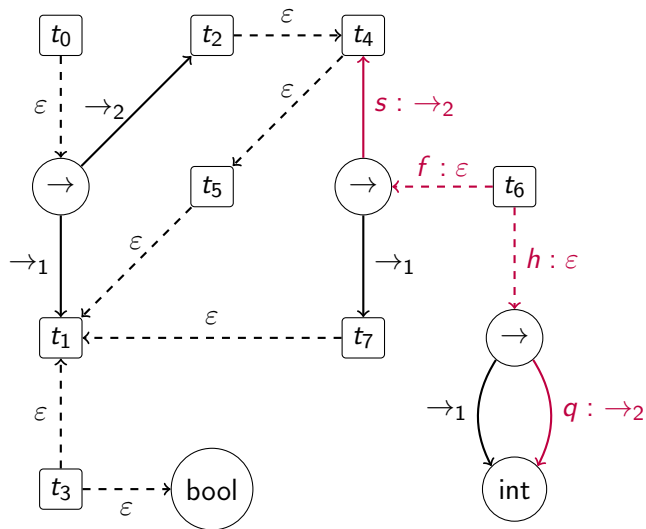
$$e : t_3 \stackrel{?}{=} t_1$$

$$f : t_6 \stackrel{?}{=} t_7 \rightarrow t_4$$

$$g : t_5 \stackrel{?}{=} t_1$$

$$h : t_6 \stackrel{?}{=} \text{int} \rightarrow \text{int}$$

$$i : t_7 \stackrel{?}{=} t_1$$




Путь унификации в факторграфе

Theorem

Если в графе унификации существует путь p из вершины u в вершину v , то в факторграфе существует путь из класса эквивалентности $[u]$ в класс эквивалентности $[v]$ с меткой $\mu_{S(\Sigma)}(l(p))$

Theorem

Если в факторграфе унификации существует путь p' из класса эквивалентности $[u]$ в класс эквивалентности $[v]$, то в графе унификации существует путь p из u в вершину v с меткой, чья нормальная форма $\mu_{S(\Sigma)}(l(p)) = p'$



Алгоритмы унификации через поиск путей

Два терма унифицируются, тогда и только тогда, когда между ними есть путь унификации, нормальная форма которого — ε

Два терма унифицируются, тогда и только тогда, когда между ними есть путь унификации, метка которого в полудиковом языке $S^0(\Sigma)$

- Один алгоритм ищет кратчайшие пути, работает за $O(n^3)$
- Второй алгоритм интегрируется в стандартный алгоритм унификации, работает на константу хуже и строит не самые маленькие доказательства унифицируемости (но и не самые плохие)